



★ PROVA FINALE DI ALTA FORMAZIONE ITS

ERMES KNOWLEDGE

Sistema RAG Enterprise Local-First con Garanzie di
Sicurezza, DLP e Isolamento

Candidato: [Nome e Cognome]

Corso: Tecnico Superiore Sviluppo Software e AI

Azienda Partner: [Nome Azienda / Stage]

Tutor Aziendale / ITS: [Nome Tutor] / [Nome Tutor]

Anno Formativo: 2025 / 2026

1. Il Problema Aziendale: Frammentazione e Rischi dei LLM Generici

■ La Conoscenza Frammentata nei Silos

- **Silos Informativi:** Dati dispersi tra cartelle condivise, PDF non indicizzati e chat.
- **Tempo Perso:** Ore spese dai dipendenti per rintracciare regolamenti aggiornati.
- **Ricerca Tradizionale Cieca:** Il keyword-matching classico ignora sinonimi e parafrasi.

■ I Pericoli dei Chatbot Commerciali (Cloud)


- **Allucinazioni Gravi:** Modelli che inventano risposte plausibili ma prive di riscontro.
- **Violazioni Privacy (GDPR):** Dati aziendali inviati all'esterno su server cloud terzi.
- **Zero Tracciabilità:** Nessuna prova verificabile su chi ha consultato cosa.

2. La Soluzione: Hermes Knowledge (Evidenza Prima)

■ **Local-First:** Nessun dato riservato lascia il perimetro aziendale. Embedding on-device.

■ **Evidenza Reale:** Ogni affermazione cita il documento originale scaricabile in 1 click.

■ **Zero Allucinazioni:** Se il documento manca, l'assistente dichiara l'assenza di evidenza.



3. Le 5 Regole Fondamentali, Applicate nel Codice

1. Local-First	Una chiave API cloud da sola non attiva mai l'elaborazione cloud esterna.
2. Evidenza Prima	Ogni risposta cita un documento accessibile, oppure l'assistente si astiene.
3. Isolamento Rigido	La ricerca è vincolata alla biblioteca prima che il testo arrivi all'assistente.
4. Input Non Fidato	Il testo estratto dai documenti non può mai eseguire codice o autorizzare azioni.
5. Originali Accessibili	Ogni citazione rimanda alla versione esatta del file scaricabile con 1 click.

4. Architettura del Sistema & Tech Stack Enterprise

■ Frontend UI/UX

React 18 · TypeScript · Vite · Tailwind CSS
Design System moderno e gestione responsive dello stato.

■ AI & Vector Engine

Ollama Embeddings · SQLite / JSON Store
Embedding on-device e storage documentale isolato.

■ Backend API Services

Python 3.11 · FastAPI (ASGI Asincrono)
Validazione automatica Pydantic e Swagger nativo.

■ DevOps & Testing

Docker · Docker Compose · Pytest (241 Test)
Orchestrazione scalabile e CI su GitHub Actions.

5. Il Motore di Retrieval: Chunking e Ricerca Ibrida

1. Ingestion

Parsing PDF, Word, Markdown, TXT e Web scraper.

2. Chunking

Segmentazione semantica con overlap contestuale.

3. Hybrid Search

Vettoriale (Sinonimi) + BM25 (Codici esatti).

4. RRF Fusion

Fusione con Reciprocal Rank Fusion.

■ Perché la Ricerca Ibrida vince nei contesti aziendali:

La ricerca vettoriale capisce i concetti e le parafrasi ma rischia di fallire su codici articolo specifici. Il BM25 cattura esattamente le sigle tecniche ma ignora i sinonimi. La loro combinazione raggiunge il massimo della precisione.

6. Advanced Retrieval: Re-ranker Posizionale e Deduplicazione

■ Re-ranker Posizionale Avanzato

- **Vicinanza Posizionale:** Premia i documenti in cui le parole chiave compaiono vicine nella stessa frase.
- **Bi-grammi Consecutivi:** Riconosce sequenze di vocaboli ad alta pertinenza.
- **Title Matching:** Assegna un peso superiore alle intestazioni di sezione.

■ Deduplicazione Jaccard

- **Indice di Jaccard su Shingle:** Analizza la somiglianza tra versioni simili dello stesso documento.
- **Raggruppamento Duplicati:** Identifica revisioni duplicate nella stessa biblioteca.
- **Efficienza:** Invia all'LLM solo il frammento migliore, azzerando le ridondanze.

7. Data Loss Prevention: Il Filtro PII Guard Algoritmico

■ Carte di Credito (Luhn Checksum)

Verifica matematica di Luhn (mod 10). Maschera le carte reali come [CARTA_CREDITO], ignorando numeri casuali.

■ Codici Fiscali Italiani

Pattern alfanumerico a 16 caratteri con verifica algoritmica del carattere di controllo (CIN).

■ Coordinate Bancarie IBAN

Validazione algebrica Modulo 97 (ISO 13616). Maschera solo IBAN validi come [IBAN].

■ Token JWT & API Keys

Riconoscimento pattern di token crittografici e chiavi API (sk-live, Bearer), oscurati preventivamente.

8. Governance, RBAC e Audit Log Immutabile

Ruoli di Accesso (RBAC):

- **Admin:** Gestione globale di utenti, biblioteche e registri di audit.
- **Editor:** Upload e gestione documenti nelle biblioteche abilitate.
- **Viewer:** Consultazione e ricerca in sola lettura.
- **Security 404:** Le biblioteche non autorizzate restituiscono 404 per non rivelarne l'esistenza.

The screenshot shows the 'Audit log' interface of the ERMES Knowledge system. The left sidebar contains navigation options: ASSISTENTE IA, Assistente, Biblioteche e documenti, Stato Sistema, Impostazioni, Accessi e chiavi API, and Audit Log (selected). The main content area is titled 'AUDIT LOG AMMINISTRATIVO' and includes a status message: 'Integrità del log verificata (firma HMAC valida su ogni voce)'. Below this is a table with three columns: 'Data e ora', 'Azione', and 'Attore'. The table lists several audit events, including 'library_answer' and 'document_downloaded', performed by 'admin', 'carol', and 'test' users. The bottom of the interface shows a status bar with 'Light', 'Attivo', and 'admin' indicators.

Data e ora	Azione	Attore
21/08/2026, 00:29:00	library_answer	admin
21/08/2026, 00:27:48	library_answer	admin
21/08/2026, 00:26:10	library_answer	admin
21/08/2026, 00:23:23	library_answer	admin
20/08/2026, 19:30:09	document_downloaded	carol
20/08/2026, 19:30:09	library_member_removed	test
20/08/2026, 19:30:09	library_member_changed	test
20/08/2026, 19:30:09	library_answer	test

9. Valutazione Quantitativa della Qualità: Golden Set

100%

Query Dirette (16)

Parole della domanda vicine al testo: recupero perfetto.

50% → 90%+

Query Parafrasate (8)

Concetto condiviso, zero parole in comune: la ricerca semantica locale colma il divario.

67% → 100%

Astensione (3)

Domande su argomenti assenti: il sistema dichiara l'assenza senza allucinare.

10. Qualità del Codice e Testing Automatizzato

241

TEST AUTOMATIZZATI (PYTEST)

100% Passed. Copertura completa di API, algoritmi DLP (Luhn/IBAN), Re-ranker e sincronizzazione.

Garanzie di Qualità & Continuous Integration:

- **GitHub Actions CI:** Pipeline automatizzata che blocca le regressioni a ogni commit.
- **Guardie di Sicurezza:** Nessun endpoint futuro può essere rilasciato senza autenticazione.
- **OpenAPI / Swagger:** Documentazione API RESTful interattiva ed auto-generata.

11. Governance: Analytics e Rilevamento dei Knowledge Gaps

■ Monitoraggio Query & Latenze

Tracciamento in tempo reale del volume di ricerche, tempo di risposta e gradimento delle risposte.

■ Rilevamento Knowledge Gaps

Identificazione automatica delle domande a cui il sistema non trova risposte nella documentazione aziendale.

■ Valore per il Management

Fornisce alla direzione una guida chiara su quali regolamenti o schede tecniche mancano e devono essere redatte.

12. Esperienza di Tirocinio Aziendale / Stage: Attività e Metodologia

■ Contesto Operativo

Inserimento nel team di sviluppo software dell'azienda partner [Nome Azienda].
Comprensione delle esigenze reali di gestione documentale.

■ Attività Svolte

- Progettazione architettura RAG modulare.
- Sviluppo endpoint FastAPI e interfacce React.
- Implementazione algoritmi DLP e re-ranking.

■ Metodologia Agile

Adozione di pratiche Scrum/Kanban, stand-up giornalieri, code review e versionamento git organizzato.

13. Esperienza di Tirocinio Aziendale: Impatto e Risultati

■ -70% Tempo di Ricerca

I dipendenti rintracciano procedure e schede tecniche in secondi anziché navigare cartelle complesse.

■ 100% Dati al Sicuro

Adozione dell'AI senza rischi di fughe di dati o non conformità GDPR grazie all'approccio Local-First e al DLP.

■ Crescita Professionale

Consolidamento di competenze di livello enterprise in Software Architecture, AI Engineering e DevOps.

14. Conclusioni e Roadmap Evolutiva Enterprise

FASE 1: ENTERPRISE IAM

Integrazione Single Sign-On (SSO) con Microsoft Entra ID / Keycloak e SCIM.

FASE 2: SCALABILITÀ CLOUD

Migrazione a Vector DB distribuiti (Qdrant cluster) e code asincrone Redis.

FASE 3: OSSERVABILITÀ

Tracciamento distribuito con OpenTelemetry, metriche Prometheus e Grafana.

Grazie per l'attenzione! — Spazio per Domande e Risposte (Q&A;)